

APLICAÇÃO DO ALGORITMO K-MEANS EM APRENDIZADO NÃO SUPERVISIONADO

Disciplina: GCC 128 - Inteligência Artificial - Universidade Federal de Lavras (UFLA)

Discente(s):Thales Maia Mendonça Negrão

Introdução e Objetivo:

O aprendizado de máquina não supervisionado busca extrair padrões intrínsecos e estruturas latentes de conjuntos de dados sem a necessidade de rótulos prévios. Dentre as técnicas mais difundidas, destaca-se o algoritmo **K-Means**, cujo objetivo é particionar N observações em K grupos (clusters), minimizando a variância interna de cada grupo.

Metodologia e Pré-processamento

Base de Dados e Seleção de Atributos


Base Utilizada: *Iris.csv*, contendo 150 instâncias divididas igualmente entre três espécies de flores (*Iris-setosa*, *Iris-versicolor* e *Iris-virginica*).

Atributos Selecionados: Foram utilizados os **4 atributos quantitativos** disponíveis: Comprimento da Sépala (*SepalLengthCm*), Largura da Sépala (*SepalWidthCm*), Comprimento da Pétala (*PetalLengthCm*) e Largura da Pétala (*PetalWidthCm*), descartando-se apenas a coluna identificadora (*Id*).

Experimentos e Análise dos Resultados


A aplicação foi executada testando diferentes valores para o número de clusters (**K**), com foco especial em $K = 2, 3, 7$.

- **Análise para $K = 2$**
 - **Comportamento:** O algoritmo isolou perfeitamente a espécie *Iris-setosa* em um cluster exclusivo devido à sua alta separabilidade linear, mas agrupou as espécies *Iris-versicolor* e *Iris-virginica* em uma única partição.
 - **Métricas:** Apresentou excelente **Silhouette Score** 0.68 pela clara distinção do primeiro grupo, mas acurácia global reduzida 66% no mapeamento externo por não conseguir individualizar a segunda e terceira classes.




• Análise para K = 3 (Valor Ideal)

- **Comportamento:** Reflete diretamente a cardinalidade real da base de dados botânica. O K-Means separou satisfatoriamente as três espécies, traçando limites consistentes entre as instâncias, com pequenas zonas de sobreposição natural nas fronteiras entre *versicolor* e *virginica*.
- **Métricas:** O **Silhouette Score** estabilizou-se em patamar saudável (≈ 0.55), enquanto a **Acurácia Global** alcançou aproximadamente **90%**, corroborada por ótimos índices de precisão e revocação macro.



• Análise para K = 7

- **Comportamento:** Ao forçar um número excessivo de partições, o algoritmo fragmentou artificialmente os dados em sub-regiões restritas.
- **Métricas:** Embora a **Inércia (WCSS)** tenha diminuído drasticamente (efeito matemático esperado pelo aumento do número de centróides), o **Silhouette Score despencou 0.35**, evidenciando forte perda de coesão e forte sobreposição entre os clusters formados (sintoma clássico de *overfitting* não supervisionado).



• Comparação com KNN:



- Em comparação com o algoritmo KNN apresentou mais fácil de funcionamento pois não exige um treinamento prévio, mas se conhecer a quantidade de cluster, esse algoritmo seria de mais fácil de adaptabilidade para mudanças pois pode processar a adição de novos grupos pode colocar a variação automática de adição e remoção de cluster (caso a quantidade de classes

mude) sem precisar de uma base de dados de treino, apenas analisando as métricas dos dados.

Métricas de Avaliação dos Agrupamentos

Para a fundamentação analítica, foram empregadas duas categorias de métricas:

- **Métricas Internas (Não Supervisionadas):**
 - **Inércia / WCSS (Within-Cluster Sum of Squares):** Mensura a compactação interna dos grupos. Observou-se queda monotônica com o aumento de K.
 - **Silhouette Score:** Avalia o quão distante um objeto está dos clusters vizinhos (varia de -1 a +1). Apresentou os melhores resultados para K = 2 e K = 3.
- **Métricas Externas (Via Mapeamento Ótimo de Rótulos / Algoritmo Húngaro):**
 - Utilizadas em caráter comparativo com os rótulos reais conhecidos para o cálculo de **Acurácia**, **Precisão**, **Revocação** e geração da **Matriz de Confusão**.



○

Visualização de Dados Multidimensionais

Como o conjunto de dados possui 4 dimensões, recorreu-se à técnica de **Análise de Componentes Principais (PCA)** para a redução dimensional para um plano bidimensional. O uso do PCA permitiu projetar as instâncias e os centroides em duas Componentes Principais (CP1 e CP2), retendo a maior parte da variância explicada total do conjunto original sem perda significativa de interpretação.

Conclusão

O desenvolvimento prático permitiu constatar a eficácia do K-Means na descoberta de estruturas em bases não rotuladas. Constatou-se que a escolha criteriosa de K (apoiada pelo conhecimento prévio do domínio ou por métodos empíricos como o Cotovelo e a Silhueta) é determinante para a qualidade do agrupamento. O uso de pré-processamento adequado e de técnicas de redução dimensional como o PCA revelaram-se fundamentais para a correta visualização e interpretação analítica dos resultados obtidos.

Anexos

[1] Link do vídeo no final do repositório:

<https://vimeo.com/1227618655?share=copy&fl=sv&fe=ci>